

Komparativna analiza metoda monokularne procene dubine

uz evaluaciju robustnosti u degradiranim uslovima

Jovan Cvijanović · SV83/2024

Vukan Radojević · SV67/2023

Osnovi računarske inteligencije · NYU Depth V2

Problem i motivacija

Monokularna procena dubine — predviđanje udaljenosti svakog piksela iz **jedne RGB slike**, bez LiDAR-a i stereo kamere.

- Direktni senzori (LiDAR, ToF) su skupi i teški za integraciju.
- Kamera je već svuda: telefon, robot, vozilo.


Ključno pitanje: kako se modeli ponašaju u **degradiranim uslovima** — magla, noćna vožnja, zamućenje?

To su **safety-critical** scenariji u autonomnoj vožnji i robotici.

Skup podataka: NYU Depth V2

- **407 zatvorenih (indoor) scena**, ~120k RGB–depth parova (trening podskup ~50k).
- Rezolucija **640 × 480**, dubina merena Kinect senzorom.
- Opseg dubine **0–10 m**, gustina anotacije ~100%.
- Cilj: **mapa dubine po pikselu (u metrima)**.

Test: 654 slike (Eigen split) + sintetički degradirane verzije.



RGB ulaz i pripadajuća mapa dubine (metri).

Maske i priprema podataka

Nule nisu 0 metara. Senzorska vrednost `0` = **nedostajuće merenje** (rupa u dubini), ne stvarna dubina.

- Svaki uzorak nosi bulovsku `valid_mask`.
- **Gubitak i sve metrike računaju se samo nad validnim pikselima.**

Promena veličine (resize)

- **RGB** → **bilinearno**.
- **Dubina** → **nearest** (nikad ne mutiti ivice dubine).

Opseg: ceo pipeline pretpostavlja NYU **0–10 m**.

Maskiranje je najčešći izvor tihih grešaka — bez njega metrike i gubitak "kažnjavaju" prazne piksele.

Pet pristupa

1 · Baseline

ResNet-50 enkoder + lagani dekodler, treniran **end-to-end**. Donja referenca.

2 · SD-UNet

Zamrznut Stable Diffusion UNet; osobine nose geometriju i semantiku.

3 · I-JEPA

Zamrznut ViT enkoder; semantički bogate patch reprezentacije.

4 · Fuzija

SD + I-JEPA osobine (konkatenacija) + dekodler i fuzioni modul.

5 · DepthAnything

SOTA model, **bez treniranja** (zero-shot). Gornja referenca.

Zajedničko

Isti dekodler, ista metrika, ista NYU evaluacija — **jedan red rezultata po pristupu**.

Zašto baš zamrznute osobine?

Stable Diffusion UNet

Tokom generativnog predtreniranja na milijardama slika uči **višeskalne** reprezentacije koje kodiraju i **geometriju** i **semantiku** scene — tačno ono što je potrebno za dubinu.

I-JEPA

Predviđa **latentne** reprezentacije maskiranih regiona (za razliku od MAE koji rekonstruiše piksele) → semantički bogati, apstraktni embedinzi.

Velike predtrenirane mreže već "razumeju" scenu. Umesto skupog treniranja od nule, na vrh stavljamo **jeftin dekode**r i iskorišćavamo to znanje.

Metod: zamrznut enkoder + lagani dekoder



■ **zamrznuto** (bez gradijenata) · ■ **trenira se** — kod fuzije se dodatno trenira i fuzioni modul.

- Enkoderi ostaju **potpuno zamrznuti**; uči se samo dekoder (SiLog gubitak).
- Ista arhitektura dekodera za pristupe 2–4 → poštena poređenja.

Gubitak: scale-invariant log (SiLog)

$$\mathcal{L}_{\text{SiLog}} = 10 \sqrt{\frac{1}{n} \sum_i g_i^2 - \lambda \left(\frac{1}{n} \sum_i g_i \right)^2}$$

$$g_i = \log \hat{d}_i - \log d_i, \quad i \in M, \quad \lambda = 0.85$$

M = validni pikseli, $n = |M|$. Standardni gubitak za dubinu.

- Poredi **logaritme** predikcije i GT → radi kroz ceo opseg 0–10 m.
- Član $\lambda(\bar{g})^2$ **oduzima deo greške konstantne skale**, pa se više kažnjava **struktura po pikselu** nego globalni ofset.
- Računa se **samo nad validnim pikselima**.

Evaluacija: metrike i protokol

$$\text{AbsRel} = \frac{1}{|M|} \sum_{i \in M} \frac{|d_i - \hat{d}_i|}{d_i}$$

$$\text{RMSE} = \sqrt{\frac{1}{|M|} \sum_{i \in M} (d_i - \hat{d}_i)^2}$$

$$\delta_1 = \% \left\{ \max \left(\frac{d_i}{\hat{d}_i}, \frac{\hat{d}_i}{d_i} \right) < 1.25 \right\}$$

M = validni pikseli (maska). AbsRel, RMSE ↓ bolje; δ_1 ↑ bolje.

Protokol

- Sve metrike samo preko **validnih piksela**.
- **Eigen center crop** → uporedivo sa literaturom.
- Median-poravnanje samo za zero-shot SOTA (pristup 5).

Degradacije (bez retreniranja)

- **Magla · Zamućenje · Podeksponiranost**
- svaka u 3 jačine: **light / moderate / severe**.

Srodni radovi i tehnološki stek

Srodni radovi

- **DepthAnything V2 / V3** — SOTA zero-shot dubina.
- **Marigold** — SD prenamenjen za dubinu.
- **GeoWizard** — SD osobine za geometriju scene.
- **MiDaS** — robusna relativna dubina (mešani skupovi).
- **I-JEPA** — self-supervised latentno predviđanje.

Tehnološki stek


- **PyTorch** — trening pipeline.
- **HF Diffusers** — SD UNet osobine.
- **HF Transformers** — I-JEPA ViT enkoder.
- **torchvision** — ResNet-50, transformacije.
- **Albumentations** — sintetičke degradacije.
- **Weights & Biases** — praćenje eksperimenata.

Rezultati i robustnost

Rezultati na čistom test skupu

#	Pristup	AbsRel ↓	RMSE ↓	$\delta 1$ ↑
1	ResNet-50	0.1376	0.4949	0.8224
2	SD-UNet	0.0802	0.3113	0.9467
3	I-JEPA	0.1314	0.4884	0.8329
4	Fuzija	0.0827	0.3218	0.9410
5	DepthAnything	0.0688	0.3244	0.9497

Podebljano = najbolje. Pristupi 1–4 trenirani na NYU; 5 je zero-shot referenca.



Ključni nalazi (čist skup)

Zamrznuti SD $\approx$ SOTA

SD-UNet **0.0802** AbsRel je na korak od DepthAnything (0.0688) — a SOTA uz to dobija **GT-median skalu**. Po RMSE je SD čak **najbolji** (0.311).

Fuzija ne pobeđuje sam SD

0.0827 vs 0.0802 — SD osobine već nose geometriju; slabija I-JEPA grana ih blago razblažuje.


Zamrznuti enkoderi » nadgledani baseline. SD, I-JEPA i DA nadmašuju end-to-end ResNet-50, iako se kod njih trenira **samo dekođer**.

Robustnost: sintetičke degradacije

Iz originalnog test skupa generišemo **9 degradiranih verzija** i evaluiramo **iste modele bez ikakvog retreniranja**.


- **Magla** — homogena, raste s dubinom.
- **Zamućenje** — Gaussovo (motion/defocus).
- **Podeksponiranost** — smanjena ekspozicija (noć).

Svaka u **3 jačine**: **light** → **severe**.



Ista scena kroz 3 tipa × 3 jačine degradacije.

Robustnost: nalazi



- **Zamućenje skoro bezopasno** za zamrznute modele (SD $\delta 1$ 0.947 $\rightarrow$ 0.917). Baseline je izuzetak (0.822 $\rightarrow$ 0.548).
- **Podeksponiranost = univerzalni pad** — svi kolabiraju ($\delta 1 \approx 0.39$ –0.49). Kritičan low-light slučaj.

- **Trenirani SD robusniji na maglu** od zero-shot DepthAnything (0.148 vs 0.251 AbsRel, teška magla).
- **Baseline najslabiji** svuda — robustnost dolazi od zamrznutih foundation osobina.

Robustnost: pun pregled (AbsRel ↓)

Model	čist	m·L	m·M	m·S	b·L	b·M	b·S	e·L	e·M	e·S
ResNet-50	0.1376	0.2663	0.3093	0.3385	0.1471	0.1680	0.2202	0.1961	0.2882	0.3271
SD-UNet	0.0802	0.1005	0.1213	0.1482	0.0804	0.0858	0.0947	0.1186	0.2363	0.3574
I-JEPA	0.1314	0.1607	0.1740	0.1891	0.1321	0.1379	0.1547	0.1844	0.2870	0.3914
Fuzija	0.0827	0.1003	0.1163	0.1373	0.0826	0.0869	0.0945	0.1214	0.2399	0.3799
DepthAny.	0.0688	0.1355	0.1909	0.2511	0.0708	0.0790	0.1033	0.0994	0.1944	0.3093

m = magla · b = zamućenje · e = ekspozicija; L / M / S = light / moderate / severe. Puna 5×10 matrica; δ1 verzija u [outputs/robustness.json](#).

Magla i ekspozicija najviše degradiraju; zamućenje jedva menja frozen modele. SD/Fuzija najstabilniji do teške degradacije.

Efikasnost: parametri i inferenca

#	Model	Trenabilni ↓	Ukupno	ms/img ↓
1	ResNet-50	30.2 M	30.2 M	6.5
2	SD-UNet	5.7 M	948.9 M	98.6
3	I-JEPA	7.9 M	638.7 M	142.5
4	Fuzija	11.3 M	1585.2 M	239.7
5	DepthAnything	0	97.5 M	60.5

Zamrznuti pristupi treniraju samo **6–11 M** parametara — daleko manje od baseline-ovih 30 M.

Kompromis: ogromni zamrznuti enkoderi čine ih **15–37× sporijim** u inferenci; fuzija (dva enkodera) je najsporija.

Tačnost naspram efikasnosti

ResNet-50

6.5 ms Najbrži, ali **najslabiji** i najmanje robustan. Kad je latencija presudna.

SD-UNet / Fuzija

~0.08 AbsRel **Skoro-SOTA** uz malo trenabilnih params, ali **99–240 ms** (veliki enkoderi).

DepthAnything

0.069 AbsRel Najbolji, ali zero-shot uz **median-oracle** skalu; 60 ms.

Nema "besplatnog ručka": zamrznute osobine kupuju tačnost i robustnost **cenom inference**. Izbor zavisi od budžeta latencije.

Ograničenja i napomene

- **DepthAnything nije potpuno fer poređenje** — metric-indoor model uz **median-poravnanje** ka GT; bez toga AbsRel ~ 0.24 (ofset skale).
- **DepthAnything V3 nije evaluiran** — nije u `transformers`, traži custom wrapper (budući rad).
- **NYU-only opseg** — sve pretpostavlja indoor 0–10 m; bez tvrdnji za outdoor/veće daljine.
- **Degradacije su sintetičke** — realistične, ali nisu prava magla/noć.

Zaključak i budući rad

Zaključak

- Zamrznute osobine velikih modela daju **skoro-SOTA tačnost** uz **jeftino** treniran dekodera.
- One su i **glavni izvor robustnosti** pod degradacijom.
- Fuzija ne donosi dobitak kad SD već nosi geometriju.

Budući rad

- **Podeksponiranost** je nerešen, safety-critical slučaj → fine-tuning na degradiranim podacima.
- Integracija **DepthAnything V3** (custom wrapper).
- Redukcija cene inference velikih enkodera.

Hvala na pažnji

Pitanja?

Jovan Cvijanović · Vukan Radojević

Cyclops · Monokularna procena dubine na NYU Depth V2