

Specifikacija projekta

Osnovi računarske inteligencije

Komparativna analiza metoda monokularne procene dubine sa evaluacijom robustnosti u degradiranim vizuelnim uslovima

Autori: Jovan Cvijanović (SV83/2024)
Vukan Radojević (SV67/2023)

Naziv teme

Komparativna analiza metoda monokularne procene dubine sa evaluacijom robustnosti u degradiranim vizuelnim uslovima

Definicija problema

Procena dubine iz jedne slike je zadatak predviđanja udaljenosti svakog piksela od kamere na osnovu jedne RGB slike, bez lidarskih senzora ili stereo kamera.

Direktni senzori dubine – lidar i Time-of-Flight kamere – skupi su i teško se integrišu u sisteme opšte namene. Kamera koja se već nalazi na vozilu, robotu ili mobilnom telefonu mogla bi uz adekvatan model da pruži dovoljno preciznu procenu dubine za navigaciju, rekonstrukciju 3D scena i proširenu realnost. Isto tako posebno je bitno razumeti kako modeli reaguju na degradirane uslove – maglu, noćnu vožnju, mutne slike – budući da se upravo tu javljaju bezbednosno kritični scenariji u autonomnoj vožnji i robotici.

Skup podataka

Koristiće se skup podataka:

NYU Depth V2 ([link](#)) – 407 scena zatvorenog prostora, ~120 000 anotiranih RGB–dubina parova (trening podskup: 50 000 slika), rezolucija 640×480 px, opseg dubine 0–10 m. Dubina je izmerena Kinect senzorom, gustina anotacije blizu 100%. Ciljno obeležje: pikselska mapa dubine u metrima.

Augmentovani test skup: iz originalnog test podskupa sintetički će se generisati degradirane verzije – homogena magla, Gausovo zamućenje i smanjenje ekspozicije.

Metodologija

Istražuje se pet pristupa koji se razlikuju po strategiji ekstrakcije vizuelnih reprezentacija i trošku treniranja, a svi rešavaju isti zadatak: predikcija guste mape dubine iz RGB slike.

1. Supervised baseline (ResNet-50 + dekodер)

Encoder-decoder arhitektura sa ResNet-50 enkoderom i lightweight dekoderskim modulom, trenirana nadgledano, služi kao donja referentna tačka.

2. Frozen Stable Diffusion UNet + trenirani dekodер

SD UNet u međuslojevima razvija višerazmerne reprezentacije koje enkoduju geometriju i semantiku scene. Koriste se aktivacije iz više nivoa zamrznutog UNet-a kao feature mapa, nad kojom se trenira lightweight dekodер za regresiju dubine.

3. Frozen I-JEPA encoder + trenirani dekodер

I-JEPA uči patch-level semantičke reprezentacije predviđanjem latentnih reprezentacija maskiranih regiona – za razliku od MAE koji rekonstruiše piksele. Frozen ViT enkoder daje semantički bogate embedinge, nad njima se trenira isti tip dekodera kao u pristupu 2.

4. Fuzija SD + I-JEPA + trenirani dekodер

SD features su teksturalno bogati i geometrijski precizni, dok su I-JEPA features semantički i strukturalni. Istražuje se fuzija oba frozen enkodera – konkatencijom feature mapa ili cross-attention modulom. Dekodер i fuzijski modul se treniraju od nule, enkodери ostaju zamrznuti.

5. DepthAnything V2 i V3 – samo evaluacija

SOTA modeli koriste se bez dodatnog treniranja kao gornja referentna tačka za kontekstualizaciju rezultata ostalih pristupa.

Trening protokol: svi pristupi koji zahtevaju treniranje (1–4) treniraju se i evaluiraju zasebno na skupu NYU Depth V2. U pristupima 2–4 trenira se isključivo dekodер (i fuzijski modul u pristupu 4), dok enkodери ostaju zamrznuti.

Analiza robustnosti: svi modeli evaluiraju se na originalnim i augmentovanim test skupovima. Kao opciono proširenje istražiće se fine-tuning odabranih modela na mešavini originalnih i degradiranih trening podataka.

Način evaluacije

Za evaluaciju se koriste standardne metrike za procenu dubine: AbsRel, RMSE i $\delta < 1.25$, sa uobičajenim definicijama iz literature.

Primarna evaluacija – standardni uslovi

Svi modeli evaluiraju se na originalnom test podskupu NYU Depth V2 odvojeno. Ovo je osnova komparacije između pristupa i omogućava direktno poređenje sa rezultatima iz literature.

Sekundarna evaluacija – robustnost

Isti istrenirani modeli evaluiraju se bez ponovnog treniranja na sintetički degradiranoj verziji originalnog NYU Depth V2 test podskupa (homogena magla, Gausovo zamućenje, smanjenje ekspozicije).

Ostale dimenzije poređenja

Pored tačnosti predikcije, modeli se porede i po: broju parametara koji se treniraju, ukupnom vremenu treniranja i vremenu inferencije po slici.

Tehnologije

- **Python 3.10+**, **PyTorch** – implementacija i trening.
- **Hugging Face Diffusers** – SD UNet feature ekstrakcija.
- **Hugging Face Transformers** – I-JEPA ViT enkoder.
- **torchvision** – ResNet-50 backbone, transformacije.
- **Albumentations** – sintetička augmentacija (magla, blur, ekspozicija).
- **Weights & Biases** – praćenje eksperimenata i metrika.
- **GPU okruženje**: NVIDIA GPU sa CUDA podrškom.

Primeri postojećih rešenja

- **DepthAnything V2** – github.com/DepthAnything/Depth-Anything-V2
- **DepthAnything V3** – github.com/bytedance-seed/depth-anything-3
- **Marigold** (SD za procenu dubine) – github.com/prs-eth/Marigold
- **GeoWizard** (SD features za geometriju scene) – github.com/fuxiao0719/GeoWizard
- **MiDaS** – github.com/isl-org/MiDaS

Relevantna literatura

- Yang et al., *Depth Anything V2*, NeurIPS 2024. – arxiv.org/abs/2406.09414
- Ke et al., *Repurposing Diffusion-Based Image Generators for Monocular Depth Estimation (Marigold)*, CVPR 2024. – arxiv.org/abs/2312.02145
- Assran et al., *Self-Supervised Learning from Images with a Joint-Embedding Predictive Architecture (I-JEPA)*, CVPR 2023. – arxiv.org/abs/2301.08243
- Zhao et al., *Unleashing Text-to-Image Diffusion Models for Visual Perception*, 2023. – arxiv.org/abs/2303.02153
- Ranftl et al., *Towards Robust Monocular Depth Estimation: Mixing Datasets for Zero-Shot Cross-Dataset Transfer (MiDaS)*, TPAMI 2022. – arxiv.org/abs/1907.01341
- Silberman et al., *Indoor Segmentation and Support Inference from RGBD Images (NYU Depth V2)*, ECCV 2012. – [link](#)
- Rombach et al., *High-Resolution Image Synthesis with Latent Diffusion Models (Stable Diffusion)*, CVPR 2022. – arxiv.org/abs/2112.10752
- Lin et al., *Depth Anything 3: Recovering the Visual Space from Any Views*, 2025. – arxiv.org/abs/2511.10647